

# 基于蚁群优化算法递归神经网络的 短期负荷预测

邹政达, 孙雅明, 张智晟

(天津大学 电气与自动化工程学院, 天津市 南开区 300072)

## SHORT-TERM LOAD FORECASTING BASED ON RECURRENT NEURAL NETWORK USING ANT COLONY OPTIMIZATION ALGORITHM

ZOU Zheng-da, SUN Ya-ming, ZHANG Zhi-sheng

(School of Electrical Engineering and Automation, Tianjin University, Nankai District, Tianjin 300072, China)

**ABSTRACT:** To overcome the defects of neural network (NN) using BP algorithm such as slow convergence rate and easy to fall into local minimum, a recurrent NN model based on ant colony optimization algorithm (ACO-RNN) is proposed. The simulation results of daily and weekly loads forecasting for actual power system show that the proposed forecasting model can effectively improve the accuracy of short-term load forecasting (STLF) and this model is stable and adaptable for both workday and rest-day, in addition, its forecasting performance is far better than that of BP-RNN and GA-RNN.

**KEY WORDS:** Ant colony optimization algorithm; BP algorithm; Recurrent Neural Network; Short-term load forecasting; Power System

**摘要:** 为了克服 BP 算法收敛速度慢和易于陷入局部最小的不足, 作者提出将蚁群优化算法用于短期负荷预测的递归神经网络模型学习算法, 对实际负荷系统日、周预测的仿真测试表明, 该模型能有效地提高短期负荷预测的精度, 对工作日和休息日都具有良好的稳定性和适应能力, 其预测性能明显优于基于 BP 算法的递归神经网络 (BP-RNN) 和基于遗传算法的递归神经网络 (GA-RNN)。

**关键词:** 蚁群优化算法; BP 算法; 递归神经网络; 短期负荷预测; 电力系统

## 1 引言

短期负荷预测 (Short-term Load Forecasting, STLF) 在实现现代电力系统的安全和经济运行中起着重要作用, 是能量管理系统的重要组成部分。电力系统 STLF 的准确性将直接影响电力市场运营的有效性。因此预测的准确性对电力系统的运行和经济性都具有重要意义。

随着人工智能和优化技术的发展, STLF 的应用研究已发展到广泛深入阶段。早期研究中普遍采用基于 BP 算法的神经网络 (BP-NN), 但 BP-NN 有易陷入局部极小点、收敛速度慢等不足, 为此又提出了不少改进算法、启发式优化算法和不同类型的神经网络 (NN)。本文主要研究用蚁群优化 (Ant Colony Optimization, ACO) 算法训练 NN, 并证实了用其改善 STLF 模型预测性能的可行性。

ACO 算法是由意大利学者 M. Dorigo 等人在 1991 年提出的<sup>[1,2]</sup>, 它是一种新型的模拟进化算法, 具有正反馈, 分布式计算, 启发性收敛等特性。用 ACO 算法对 NN 进行启发式学习训练 (ACO-NN), 可克服 BP-NN 的不足, 且可提高 ACO-NN 的泛化能力和快速全局收敛等特点。通过对实际地区电网的负荷的预测仿真和测试, 证实了所提出的基于 ACO 算法的递归神经网络 (recurrent neural network, RNN) 的 STLF 模型能有效地提高预测精度, 且对非高温周的工作日和休息日都具有良好的预测稳定性和适应能力, 其预测性能明显优于 BP-RNN 和 GA-RNN。

## 2 蚁群优化算法的基本原理

ACO 算法是受到蚂蚁群搜索食物过程的启发而产生的, 通过对蚂蚁群行为的研究, 发现蚂蚁个体行为虽然非常简单, 但由简单个体所组成的群体却表现出极其复杂的行为。蚂蚁个体之间通过一种称之为外激素的物质进行信息传递, 即蚂蚁在运动过程中在它所经过的路径上撒播该种物质; 而且蚂蚁能够通过感知这种物质来指导它

们运动方向。因此,由大量蚂蚁组成的蚁群的集体行为便表现出一种信息正反馈过程:即某一路径上走过的蚂蚁越多,则后来者选择该路径的概率就越高。蚂蚁个体之间就是通过不断的信息交流来实现搜索食物的目的,为清晰起见,该过程可以用图1来描述<sup>[1,2]</sup>。




图1 蚂蚁搜索食物示意图

Fig.1 Schematic diagram of ants' searching food

设A是蚁巢,E是食物源,HD为障碍物。由于障碍物的存在,蚂蚁只能由A经H或D到达E,或由E经H或D到达A,各点之间的距离如图所示。设每个时间单位有30只蚂蚁由A到达B,有30只蚂蚁由E到达C,每只蚂蚁过后留下的激素量(一般称为信息素,Information Element, IE)为1。

在初始时刻 $t_0$ ,由于路径BH、BD、CH、CD上均无信息素存在,位于B和C的蚂蚁可以随机选择路径。从统计的角度可认为是以相同的概率选择这四条路径。经过一个时间单位后,由于BHC的长度是BDC长度的两倍,假设个体撒播的IE是相等的,则BDC上的信息素量是BHC上的两倍。因此 $t_1$ 时刻,将有20只蚂蚁由B和C到达D,有10只蚂蚁由B和C到达H。随着时间的推移,蚂蚁将会以越来越大的概率选择路径BDC,最终完全选择路径BDC,从而找到由蚁巢到食物源的最短路径。

ACO算法是一种具有通用目的的内启发式算法,可适用于求解大规模的组合优化问题。在ACO算法中设了一个代理集,在代理集中每个成员都像是相互协作的人工蚂蚁一样工作,通过撒播在“搜索路径”上的IE来交换信息,最终实现问题的解。人工蚂蚁移动时,表现为一边建立问题的解,一边又通过加入新的IE不断修改问题的描述。必须指出,ACO算法中的人工蚂蚁与实际蚂蚁是有某些区别的<sup>[4]</sup>,人工蚂蚁是作为一种最优工具来运作,并不是自然界中实际蚂蚁的模拟。由此可见,ACO算法的主要特征是:正反馈作用有助于快速发现较好的解;分布式的计算可避免迭代过程中的早熟现象;启发性收敛则使搜索过程中更早发现可接受解成为可能。

ACO算法特点使其在求解复杂优化问题时具有明显的优势,在许多领域及电力部门中得到了研究、

应用和测试,并取得显著成绩;研究者根据具体目标提出了更新IE不同方法的各种改进算法,在1998年10月召开第一届蚂蚁优化国际研讨会。目前研究较多的有:大规模组合优化问题<sup>[3-6]</sup>、二次分配问题(优化规划属于此类)<sup>[7-9]</sup>、调度问题<sup>[10,11]</sup>等。

### 3 基于蚁群优化算法的神经网络训练

目前,大多数NN都使用梯度下降法进行训练,如改进BP算法,或用模拟退火算法、禁忌搜索法、遗传算法等。ACO算法是一种全局优化的启发式算法,从其原理分析可用作NN的学习算法<sup>[12-14]</sup>,ACO算法中许多参数的协调选择是重要问题,文献[15]是对TSP问题的经验选择。为此本文须根据负荷预测目标进行研究和探索。算法的基本过程为

假定网络中有 $m$ 个参数,它包括所有权值和阈值。蚁群中蚂蚁的数目为 $h$ 。

首先,对于NN参数 $p_i$  ( $1 \leq i \leq m$ ),取其 $N$ 个可能的随机非零值,组成集合 $I_{p_i}$ ,令 $\tau_j(I_{p_i})(t)$ 表示 $t$ 时刻集合 $I_{p_i}$  ( $1 \leq i \leq m$ )中第 $j$ 个元素 $p_j(I_{p_i})$ 的IE。开始时如有 $h$ 只蚂蚁的蚁群从蚁巢出发去寻找食物,每只蚂蚁从集合 $I_{p_i}$ 中随机地选择一个元素,它表示赋予该蚂蚁的IE。当蚁群中的蚂蚁在所有集合中完成选择元素后,即到达食物源。此后,按一定的规则调节集合中元素的IE。这一过程反复进行,当进化趋势不明显或是达到指定迭代次数时搜索结束。

本文用蚁群算法训练NN的主要步骤如下

(1) 令时间 $t$ 和迭代次数 $NC$ 为零,设置最大迭代次数 $NC_{max}$ ,初始化所有集合 $I_{p_i}$  ( $1 \leq i \leq m$ ),令每个集合中的每个元素在初始时刻的信息素 $\tau_j(I_{p_i})(0) = 0$ ,且 $\Delta\tau_j(I_{p_i}) = 0$ ,将所有蚂蚁置于蚁巢。

(2) 启动所有蚂蚁,对蚂蚁 $k$  ( $k=1 \cdots h$ )根据下述路径选择概率规则,计算的概率用轮盘转法选择集合 $I_{p_i}$ 中的元素。

路径选择规则:对于集合 $I_{p_i}$ ,蚂蚁 $k$ 根据式(1)计算的概率 $P$ 随机地选择它的第 $j$ 个元素。

$$P(\tau_j^k(I_{p_i})) = (\tau_j(I_{p_i})) / \sum_{g=1}^N \tau_g(I_{p_i}) \quad (1)$$

(3) 重复步骤(2),直到蚁群中的所有蚂蚁全部到达食物源。

(4) 置 $t:=t+m$ ,  $NC:=NC+1$ ,依据各蚂蚁选择的权值计算NN的输出和误差,记录当前最优解。根据下述的IE调节规则更新集合 $I_{p_i}$ 中的每

个元素的 IE。

IE 调节规则: 随着时间的推移, 先前留下的 IE 逐渐消逝, 用参数  $\rho$  ( $0 \leq \rho < 1$ ) 表示 IE 的残留程度, 则  $1-\rho$  表示 IE 的消逝程度, 经过  $m$  个时间单位, 蚂蚁从蚁巢到达食物源的各路径上的 IE 要根据式(2)和式(3)作调整

$$\tau_j(I_{p_i})(t+m) = \rho \tau_j(I_{p_i})(t) + \Delta \tau_j(I_{p_i}) \quad (2)$$

$$\Delta \tau_j(I_{p_i}) = \sum_{k=1}^h \Delta \tau_j^k(I_{p_i}) \quad (3)$$

式中  $\Delta \tau_j^k(I_{p_i})$  表示第  $k$  只蚂蚁本次循环中在集合  $I_{p_i}$  的第  $j$  个元素  $p_j(I_{p_i})$  上留下的 IE, 可用下式计算

$$\Delta \tau_j^k(I_{p_i}) = \begin{cases} \frac{Q}{e^k} & \text{第 } k \text{ 只蚂蚁在本次循环中} \\ & \text{选择元素 } p_j(I_{p_i}) \\ 0 & \text{其他} \end{cases} \quad (4)$$

式(4)中  $Q$  是常数, 用作调节 IE 的调整速度,  $e^k$  是将第  $k$  个蚂蚁选择的一组元素作为 NN 权值时, 训练样本集后的最大输出误差, 可由式(5)计算。

$$e^k = \max_{p=1}^S |O - O_{ex}| \quad (5)$$

式(5)中  $O$  和  $O_{ex}$  分别是 NN 的实际输出和期望输出, 故  $e^k$  越小, 相应 IE 增加就越多。

(5) 当进化趋势不明显或迭代次数  $NC \geq NC_{max}$ , 则迭代结束, 输出最优解。否则转步骤(2)。

在 ACO 算法中,  $Q$  和  $\rho$  是重要的参数, 参数  $Q$  的大小决定路径上 IE 量的更新程度, 变量  $\rho \times \tau$  的物理含义为残留的信息量, 需要忘记一部分过去积累的信息, 可更有效利用最新的信息。这两个参数的选取对计算结果影响较大。但该参数的如何选取目前还难以用解析法来确定其最佳组合。因此参数  $Q$  和  $\rho$  是通过反复匹配和调整后的经验得到的。本文在大量仿真中归纳出的选取办法为: 因参数  $Q$  的取值范围较大, 而参数  $\rho$  的取值范围相对固定 (即  $[0, 1]$  之间), 因此可先随机设定  $\rho$  的值后再来调整  $Q$ , 得到较理想的解, 在基本确定  $Q$  值后, 再反过来调整  $\rho$ , 寻找更优的解, 如此反复, 最终逼近较为理想的参数组合。

## 4 基于蚁群优化算法的 RNN 模型构造

任何基于 NN 原理的 STLF 模型都存在模型结构确定问题, 该问题的实质是指如何确定 NN 模型的输入层、隐含层和输出层的规模。考虑到预测点

的动态性采用单步预测输出, 并反馈用作下一步预测输出的输入元素。输入矢量维数是依据文献[16]确定的饱和嵌入维数  $m=7$ , 即以预测时刻前 7 个点的负荷作为预测模型的输入维。ACO-RNN 的隐含层节点数根据训练样本集用穷举法确定节点数为 8, 预测 NN 模型的结构为 7-8-1, 输出表示为

$$y(t+\tau) = F[x(t), x(t-\tau), x(t-2\tau), \dots, x(t-(m-1)\tau)] \quad (6)$$

根据文献[16], 采用递归神经网络的结构如图 2 所示。本文主要研究 ACO 算法对预测精度性能的影响, 仅用 ACO 算法形成优化 RNN, 训练样本是按预测日前 14 天的历史负荷数据形成对应于 24 个预测点的固定训练样本集 (本文未按相空间预测点的演化轨迹确定)。




图2 递归神经网络预测模型结构

Fig.2 The structure of RNN forecasting model

在 ACO-RNN 训练和仿真测试中, 发现学习样本过多会导致网络的学习过度, 使预测精度下降, 本文中取实际负荷系统的训练样本集数为 10~15 个 (天) 时, 预测效果较好。在对预测日进行负荷预测时, 各预测点的测试样本按式(6)的预测点步进动态移动获得, 如图 2 所示。

## 5 仿真计算及预测结果比较

### 5.1 预测模型基本数据

本文通过 ACO-RNN 与改进的 BP-RNN 这两个预测模型对实际地区电网负荷系统中的日负荷预测仿真进行测试。为突出两个模型的算法对预测性能的影响, 模型均采用 7-8-1 结构的递归神经网络模型。

应用蚁群算法训练 RNN 时的各参数选为:

$\rho=0.5$ ;  $h=100$ ;  $Q=25.0$ ; RNN 参数  $p_i$  选为  $[-1, 1]$  之间的随机数;  $N=100$ 。在用 BP 算法训练 RNN 时采用自适应修改学习率的算法和动量批梯度下降算法相结合的训练方法, 最大允许误差  $\varepsilon=1 \times 10^{-5}$ ; 初始学习率为  $\eta=0.05$ ; 学习率自适应修改率  $\eta_{inc}=1.05$ ; 动量因子  $\alpha=0.9$ 。

## 5.2 两种模型日负荷预测精度及其性能分析

用实际地区电网 2001 年 3 月 30 日至 4 月 12 日数据对两个模型分别进行训练。对 2001 年 4 月 13 日进行小时/日(24 点)负荷预测,其预测误差曲线如图 3 所示。




图 3 实际地区网日负荷的预测误差及其比较

Fig.3 Errors of forecasted daily load of actual power network by ACO-RNN and BP-RNN respectively

由图 3 中曲线数据可知, ACO-RNN 和改进 BP-RNN 的两个基本指标,即最大相对误差分别为 3.173%和-7.782%;日绝对平均误差分别为 1.60%和 2.93%。可见, ACO-RNN 模型的预测性能要明显优于 BP-RNN,同时此误差值也优于文献[16]中与 GA-RNN(遗传算法)对应的 6.505%和 1.973%(所用负荷资料是同一电网而仅是不同预测日)。但 ACO-RNN 模型训练耗时 130~200s 略高于 BP-RNN 模型。

## 5.3 ACO-RNN 模型预测稳定性和适应性的分析

仅根据对某一天的预测结果不足以对 ACO-RNN 模型做出评价,通过两种模型的非高温周的预测性能来对 ACO-RNN 模型的预测精度、稳定性和适应性能力进行评价,即可分析模型对工作日和双休日的适应能力。非高温周的仿真测试和结果如表 1 所示。

表 1 实际地区电网非高温周的预测误差

Tab.1 The daily load forecasting errors of a temperate week in actual power network

星 期	日最高-最低 温度/℃	ACO-RNN		BP-RNN	
		$E_{MAPE}\%$	$E_{MAX}\%$	$E_{MAPE}\%$	$E_{MAX}\%$
一	15~7	1.64	3.12	3.19	7.35
二	12~4	■	3.17	3.28	7.95
三	16~5	1.60	3.17	2.74	7.78
四	21~7	1.65	3.51	3.29	7.54
五	17~6	1.60	3.37	2.93	7.89
六	24~10	1.68	3.54	■	8.19
日	28~10	1.67	■	3.51	■
一周平均		1.65	3.36	3.19	7.88

注:  $E_{MAPE}$  为平均误差;  $E_{MAX}$  为最大相对误差。

非高温周的预测误差指标如表 1 所示, ACO-RNN 模型的  $E_{MAPE}\%$ 和  $E_{MAX}\%$ 相应为 1.65 和 3.36;而 BP-RNN 模型的误差则为 3.19 和 7.88。显然,

ACO-RNN 的预测误差比 BP-RNN 小一半以上,而且表现出很好的预测稳定性和预测适应性,即不管是工作日还是双休日都具有适应能力。一周内  $E_{MAPE}\%$ 的变化, ACO-RNN 模型为 0.13,而 BP-RNN 模型为 1.04,可见 BP-RNN 模型的稳定性和适应能力均较差。

用 6 月 25 日到 7 月 8 日数据进行训练,连续进行高温周的预测测试数据如表 2 所示。两个误差性能指标要比表 1 的数据都增加几乎一倍左右。在表 1 中的日最高温度的变化为 15~28℃相差 13 度,而表 2 中的最高温度变化为 32~38℃,仅相差 6 度,说明预测模型不能适应外部高温引起的负荷敏感性变化。其原因为:因以预测日前两周数据为训练样本,其中仅包含有个别的高温天,导致 RNN 模型对高温天预测的泛化能力降低;其次是负荷对高温区具有极强的敏感性,且具有复杂的非线性,这也是导致 RNN 泛化能力降低的原因。因此高温区的负荷预测拟用细化高温和气象因素负荷聚类 and 模式识别原理来解决这将在另文中研究。但高温周预测性能仍能说明研究方法对工作日和双休日具有预测稳定性和适应能力。

表 2 实际地区电网高温周的预测误差

Tab.2 The daily load forecasting errors of a high temperature week in actual power network

星 期	日最高-最低温度/℃	ACO-RNN 模型	
		$E_{MAPE}\%$	$E_{MAX}\%$
一	32~24	3.42	6.41
二	32~24	3.74	6.10
三	35~24	■	6.37
四	38~26	3.66	6.58
五	36~25	3.76	■
六	33~25	3.64	6.68
日	33~24	3.25	6.55
一周平均		3.64	6.44

## 6 结论

(1) 在实际负荷预测系统中的测试结果表明,基于 ACO-RNN 的 STLF 模型能有效地提高预测精度。

(2) 通过非高温周预测证明该模型具有高的预测稳定性和适应性,一周的  $E_{MAPE}$  波动仅为 0.13%,说明对工作日和休息日有较强的适应性,这对电力市场运营是极其有利的,无须分别建模。

(3) 高温周预测数据说明,该模型不能适应由外部随机温度因素引起的负荷变化,必须采用具体的措施来解决。

## 参考文献

- [1] Dorigo M, Maniezzo V, Colomi A. Ant system: optimization by a colony of cooperating agents[J]. IEEE Trans on Systems, Man and Cybernetics, Part B, 1996, 26(1): 29-41.

- [2] Colomi A, Dorigo M, Maniezzo V. An investigation of some properties of an ant algorithm[C]. Proceedings of the Parallel Problem Solving from Nature Conference (PPSN'92)[A], Brussels, Belgium: Elsevier Publishing, 1992: 509-520.
- [3] Dorigo M, Caro G D. Ant colony optimization: a new meta-heuristic [C]. Proceedings of the 1999 congress on Evolutionary computation [A], Washington, DC: USA, 1470-1477.
- [4] Dorigo M, Gambardella L M. Ant colony system: a cooperative learning approach to the traveling salesman problem[J]. IEEE Trans on, Evolutionary Computation, 1997, 1(1): 53-66.
- [5] El-Keib A A, Sisworahardjo N S. Unit commitment using the ant colony search algorithm[C]. Power Engineering 2002, Conference on, Large Engineering Systems[A]. LESCOPE 02, Pages: 2-6.
- [6] 郝晋, 石立宝, 周家启, 等. 基于蚁群优化算法的机组最优投入[J]. 电网技术, 2002, 26(11): 26-31.  
Hao Jin, Shi Libao, Zhuo Jiaqi *et al.* Optimal unit commitment based on Ant optimization algorithm[J]. Power System Technology, 2002, 26(11): 26-31.
- [7] Maniezzo V, Colomi A, Dorigo M. The ant system applied to the quadratic assignment problem[J]. Knowledge and Data Engineering, IEEE Transactions on, 1999, 11(5): 769-778.
- [8] Merp P, Freisleben B. A comparison of memetic algorithms, tabu search, and ant colonies for the quadratic assignment problem [C]. Evolutionary Computation, CEC 99, Proceedings of the 1999 Congress on, Vol. 3, Pages: 2070.
- [9] 陈根军, 王磊, 唐国庆, 等. 基于蚁群是优的配电网规划方法[J]. 电网技术, 2003, 27(3): 71-75.  
Chen Genjun, Wang Lei, Tang Guoqing *et al.* An ant colony optimization based method for power distribution network planning [J]. Power System Technology, 2003, 27(3): 71-75.
- [10] 侯云鹤, 熊信良, 吴耀武, 等. 基于广义蚁群算法的电力系统经济负荷分配[J]. 中国电机工程学报, 2003, 23(3): 59-64.  
Hou Yunhe, Xiong Xinyin, Wu yaowu *et al.* Economic dispatch of power systems based on generalized Ant colony optimization method[J]. Proceedings of the CSEE, 2003, 23(3): 59-64.
- [11] Yu Inkeun, Chou C S, Song Y H. Application of the ant colony search algorithm to short-term generation scheduling problem of thermal units[C]. Proceedings of POCOON'98, International Conference on Power System Technology, Beijing, China, 1998, 552-556.
- [12] 洪炳熔, 金飞虎, 高庆吉. 基于蚁群算法的多层前馈神经网络[J]. 哈尔滨工业大学学报, 2003, 35(7): 823-825.  
Hong Bingrong, Jin feihu, Gao Qingji. Multi-layer feedforward neural network based on ant colony system[J]. Journal of Harbin Institute of Technology, 2003, 35(7): 823-825.
- [13] Zhang Subing, Liu Zemin. Neural Network Training Using Ant Algorithm In ATM Traffic Control[C]. The 2001 IEEE International Symposium on, 2001, Vol.2, Page(s): 157-160.
- [14] Shenghong Li, Zemin Liu. A General CAC Approach Using Novel Ant Algorithm Training Based Neural Network[C]. IJCNN '99. International Joint Conference on, 1999, Vol.3 Page(s): 1885-1888.
- [15] 詹士昌, 徐婕, 吴俊. 蚁群算法中有关算法参数的最优选择[J]. 科技通报, 2003, 19(5): 381-386.  
Zhan Shichang, Xu Jie, Wu Jun. The Optimal Selection on the Parameters of the Ant Colony Algorithm. Bulletin of Science and Technology[J]. 2003, 19(5): 381-386.
- [16] 张智晟, 孙雅明, 何云鹏. 基于相空间重构理论和优化递归神经网络结合的短期负荷预测方法[J]. 中国电力, 2004, 37(1): 19-23.  
Zhang Zhisheng, Sun Yaming, He yunpeng. A new approach of STLF based on combination of phase space reconstruction theory and optimal recursive neural networks[J]. Electric Power, 2004, 37(1): 19-23.

收稿日期: 2004-11-16.

作者简介:

邹政达 (1980-), 男, 硕士研究生, 主要研究方向为电力系统优化原理和智能负荷预测; E-mail: milandada@163.com

孙雅明 (1934-), 女, 教授, 博士生导师, 长期从事电力系统智能控制和故障识别、变电站和配网的综合自动化研究工作以及综合智能型负荷预测; E-mail: ymsun@eyou.com

张智晟 (1976-), 男, 博士后, 研究方向为综合智能型电力负荷预测以及变电站和配网的综合自动化研究工作。

(上接第58页 continued from page 58)

- [10] Serizawa Y, Shimizu K, Fujikawa F *et al.* ATM transmissions of microprocessor-based current differential teleprotection signals [J]. IEEE Trans on Power Delivery, 1999, 14(2): 335-341.
- [11] Serizawa Y, Imamura H, Sugaya N *et al.* Experimental examination of wide-area current differential backup protection employing broadband communications and time transfer systems[A]. IEEE Power Engineering Society Summer Meeting[C], 1999, Vol.2: 1070-1075.
- [12] 赵大平, 孙业成. 浅析 SDH 光纤通信传输继电保护信号的误码特性和时间延迟[J]. 电网技术, 2002, 26(10): 66-70.  
Zhao Dapin, Sun Yecheng. A preliminary analysis of characteristics of code error and time delay of protective relaying signals transmitted by SDH optical fiber communication system[J]. Power System Technology, 2002, 26(10): 66-70.
- [13] 高厚磊, 贺家李, 江世芳. 基于 GPS 的同步采样及在保护与控制中的应用[J]. 电网技术, 1995, 19(7): 30-32.  
Gao Houlei, He Jiali, Jiang Shifang. GPS-based synchronized sampling and its application in protection and control[J]. Power System Technology, 1995, 19(7): 30-32.
- [14] Serizawa Y, Myoujin M, Kitamura K *et al.* Wide-area current differential backup protection employing broadband communications and time transfer systems[J]. IEEE Trans on Power Delivery, 1998, 13(10): 1046-1052.
- [15] Serizawa Y, Imamura H, Kiuchi M. Performance evaluation of IP-based relay communications for wide-area protection employing external time synchronization[A]. IEEE Power Engineering Society Summer Meeting[C], 2001, Vol.2: 909-914.
- [16] Qin B L, Guzman-Casillas A, Schweitzer E O III. A new method for protection zone selection in microprocessor-based bus relays [J]. IEEE Trans on Power Delivery, 2000, 15(3): 876-887.
- [17] Chen W K. Graph theory and its engineering applications [M]. Singapore: World Scientific, 1997.

收稿日期: 2004-12-17.

作者简介:

苏盛 (1975-), 男, 湖南人, 博士研究生, 助教, 研究方向为电力系统继电保护;

K. K. Li 男, 副教授, 从事电力系统继电保护的研究教学工作;

W. L. Chan 男, 副教授, 从事电能质量管理及与工业微机控制的研究教学工作;

段献忠 (1966-), 男, 教授, 博士生导师, 研究方向为电压稳压、FACTS、信息化电力系统和电力市场等领域;

曾祥君 (1972-), 男, 博士, 副教授, 研究方向为电力系统微机保护与控制及信息融合技术在电力系统的应用。